Módulo 5 · Actividades de aplicación práctica

M5-AE3 · Supervisión humana y riesgos

Aprendizaje esperado: Incorporar puntos de supervisión humana y controles de riesgo en un flujo automatizado, evaluando su efecto.

› Actividad 1 · Controles para el flujo de reclamos de Paula

Cubre: H1, C1, C2

Cita: (National Institute of Standards and Technology, 2024; Grupo independiente de expertos de alto nivel sobre inteligencia artificial, 2019)

Situación

Paula, ejecutiva de atención al cliente en una tienda de electrodomésticos, ya corrigió el problema de su flujo: los reclamos con faltas o en tono informal quedaban en urgencia «baja» y nadie los leía. Ahora su jefatura quiere sumarle un paso. El flujo quedaría así: llega un reclamo por el formulario de la tienda; la IA lo clasifica en urgencia alta, media o baja y lo resume en una línea; se agrega una fila en la planilla de reclamos; el equipo atiende por orden de urgencia; y un correo automático le dice al cliente en qué plazo lo van a contactar según su urgencia.

Antes de aceptar, Paula quiere decidir dónde revisa una persona y qué hacer si algo falla. Tiene presente lo que le pasó: el NIST describe el sesgo de automatización como confiar de más en lo que entrega un sistema automático, y ese exceso de confianza agrava los errores (National Institute of Standards and Technology, 2024). Tú vas a ayudarla a armar los controles. El flujo, la tienda y los reclamos son ficticios.

Lo que vas a hacer

1. Haz un mapa de riesgos: para cada uno de los cinco pasos, escribe qué podría salir mal, si es un error en cadena, un problema de privacidad o un sesgo, y qué pasaría si nadie lo nota.
2. Clasifica el riesgo de cada paso en bajo, alto o «decide algo importante sobre una persona».
3. Ubica los puntos de control donde el riesgo es mayor, sobre todo antes de que algo salga

control humano o mando humano.

4. Escribe tres o cuatro criterios de aprobación para el punto de control más importante, cada uno como una pregunta de sí o no que se responda en pocos segundos.
5. Propón las columnas de supervisión que le faltan a la planilla de reclamos, incluidas «Dato original», «Estado» y «Revisó».
6. Escribe el plan de contingencia con sus seis respuestas: cómo se dan cuenta, cómo lo detienen, cómo sigue el trabajo mientras tanto, cómo recuperan lo que falló, a quién avisan y quién responde.

Para decidir cuánta revisión pide cada paso, usa la regla de las directrices éticas de la Comisión Europea: cuanto menor sea la supervisión posible, mayores deben ser las verificaciones (Grupo independiente de expertos de alto nivel sobre inteligencia artificial, 2019). Fíjate en que el correo al cliente es el paso más difícil de revertir, porque un correo enviado no se puede recoger.

Lo que entregas

Una tabla con los cinco pasos, su riesgo, si lleva punto de control, la forma de supervisión y la razón. Debajo, los criterios de aprobación del punto principal, las columnas nuevas de la planilla y el plan de contingencia con las seis respuestas, con un responsable con nombre y un reemplazo para cuando esa persona no esté.

Cómo se revisa

El criterio «Define puntos de control humano según el riesgo.» se da por logrado si cada punto de control está en un paso de riesgo alto, si hay uno antes del correo al cliente y si la forma de supervisión de cada punto calza con su riesgo. Se mira también que los criterios de aprobación se puedan responder con sí o no y que alguno revise los reclamos que quedan en «baja».

El criterio «Elabora un plan de contingencia para el flujo.» se da por logrado si el plan responde las seis preguntas con acciones concretas: dónde se pausa el flujo, cuál es la forma manual de seguir atendiendo, cómo se corrigen los correos que ya salieron y quién responde, con nombre. Una respuesta como «el sistema avisa» no cuenta como responsable.

› Actividad 2 · Supervisión y contingencia para tu flujo

Cubre: H1, C1, C2 **Cita:** (National Institute of Standards and Technology, 2023; University of Bath, s. f.)

Situación

Tu flujo del tema anterior funciona, pero todavía corre sin que nadie revise. Antes de que tu empresa pueda pensar en usarlo con datos reales, necesita controles y un plan para cuando falle. El marco de gestión de riesgos de IA del NIST pide definir y documentar los procesos de supervisión humana y los roles de cada persona, y tener mecanismos y responsables para desconectar o desactivar un sistema que no funciona como se espera (National Institute of Standards and Technology, 2023). La guía de la Universidad de Bath, por su parte, pide un plan de contingencia para todo flujo importante (University of Bath, s. f.).

Sigue trabajando en tu cuenta de práctica, con datos inventados o con copias sin datos sensibles.

Lo que vas a hacer

1. Haz el mapa de riesgos de tu flujo, paso por paso: errores en cadena, privacidad y sesgo.
2. Define los puntos de control según el riesgo de cada paso, con su forma de supervisión y la razón, y revisa si algún paso decide algo importante sobre una persona; si es así, esa decisión la toma una persona.
3. Escribe tres o cuatro criterios de aprobación para cada punto de control y agrega a tu planilla las columnas de supervisión, con el valor «por revisar» hasta que alguien apruebe.
4. Ubica en tu herramienta dónde se pausa o se desactiva el flujo y revisa que agregue filas en vez de reemplazar datos.
5. Escribe tu plan de contingencia con las seis respuestas, pensando en tu equipo y en la forma manual de hacer la tarea.
6. Prepara diez casos ficticios, siembra un error en tres de ellos y corre el flujo sin el control y con el control.
7. Anota cuántos errores llegaron al resultado en cada corrida, cuántas falsas alarmas hubo y cuánto te tomó revisar, y escribe una conclusión de dos líneas.

Si alguna respuesta del plan es «no sé», ese es el punto débil que tienes que resolver antes de mostrarle el flujo a tu jefatura.

Lo que entregas

Tu mapa de riesgos con los puntos de control, los criterios de aprobación, una captura de la planilla con las columnas de supervisión y datos de prueba, el plan de contingencia y la tabla con y sin control con tu conclusión. Con esto completas tu prototipo.

Cómo se revisa

El criterio «Define puntos de control humano según el riesgo.» se da por logrado si cada punto de control está justificado por el riesgo de su paso, si los pasos que salen hacia otras personas tienen revisión antes y si los criterios de aprobación son preguntas de sí o no. Se mira además que la prueba con y sin control muestre si el control detecta los errores sembrados y que la conclusión diga si vale lo que cuesta.

El criterio «Elabora un plan de contingencia para el flujo.» se da por logrado si las seis respuestas son concretas para tu flujo: cómo te das cuenta de la falla, dónde lo detienes, cómo sigue el trabajo a mano, cómo recuperas lo que falló, a quién avisas y quién responde, con nombre y con un reemplazo.

› Referencias bibliográficas

Grupo independiente de expertos de alto nivel sobre inteligencia artificial. (2019). *Directrices éticas para una IA fiable*. Comisión Europea. https://ec.europa.eu/newsroom/dae/document.cfm?doc_id=60423

National Institute of Standards and Technology. (2023). *Artificial intelligence risk management framework (AI RMF 1.0) (NIST AI 100-1)*. https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.100-1.pdf

National Institute of Standards and Technology. (2024). *Artificial intelligence risk management framework: Generative artificial intelligence profile (NIST AI 600-1)*. https://doi.org/10.6028/NIST.AI.600-1

University of Bath. (s. f.). *Automation standards for Microsoft Power Automate*. https://bath.ac.uk/guides/automation-standards-for-microsoft-power-automate