Módulo 1 · Introducción a la IA generativa y prompt básico · Caso de aplicación

Cuando la IA inventa: abogados y jurisprudencia inexistente (Mata v. Avianca, 2023) y chatbot de Air Canada (2024)

Temas que trabaja: Validación de resultados
Hito del proyecto con el que conecta: Hito 1 · Problema u oportunidad real + biblioteca de prompts v1

› 1. Contexto

Este caso junta dos historias de mundos distintos: un estudio de abogados en Nueva York y una aerolínea en Canadá. En las dos, alguien confió en un texto producido por un sistema automático sin contrastarlo con la fuente original. Y en las dos, una autoridad dejó todo por escrito en una resolución pública: un tribunal federal de Estados Unidos y un tribunal civil de Columbia Británica (Mata v. Avianca, 2023; Moffatt v. Air Canada, 2024). Por eso no dependemos de lo que contó la prensa: sabemos qué se revisó, qué no se revisó y qué consecuencias tuvo.

En la primera historia, un abogado usó ChatGPT para buscar fallos que apoyaran su argumento, y el chatbot los inventó (Mata v. Avianca, 2023). En la segunda, el chatbot del sitio web de Air Canada le dio a un pasajero una regla equivocada sobre los descuentos por duelo (Moffatt v. Air Canada, 2024). Air Canada no informó al tribunal qué tecnología usaba su chatbot, así que no podemos afirmar que fuera IA generativa (Moffatt v. Air Canada, 2024). Lo que sí está probado es que la respuesta automática estaba equivocada y que alguien tuvo que responder por ella (Moffatt v. Air Canada, 2024).

En tu trabajo también firmas, envías o publicas textos con tu nombre o el de tu empresa. Este caso muestra con hechos por qué hay que validar: una respuesta que suena segura no es una respuesta verificada.

› 2. Qué pasó

La primera historia es Mata v. Avianca. Un pasajero demandó a Avianca ante un tribunal federal de Nueva York por una lesión sufrida en un vuelo, y la aerolínea pidió rechazar la demanda por estar fuera de plazo. En el estudio que representaba al pasajero, un abogado hacía la investigación y otro firmaba y presentaba los escritos. El 1 de marzo de 2023 presentaron una respuesta que citaba decisiones judiciales que no existían (Mata v. Avianca, 2023). Quien la firmó la había revisado solo por estilo y no leyó ninguno de los fallos citados (Mata v. Avianca, 2023).

El abogado que investigó había usado ChatGPT como única fuente. Le pedía «casos que respalden» su postura, y el chatbot los inventó (Mata v. Avianca, 2023). Buscó el texto completo de uno de ellos, no lo encontró y no lo informó (Mata v. Avianca, 2023). Para comprobar, le preguntó al mismo ChatGPT si los casos eran reales, y el chatbot respondió que sí (Mata v. Avianca, 2023).

Las alertas llegaron una tras otra. El 15 de marzo, Avianca avisó que no encontraba la mayoría de los casos, y nadie retiró el escrito (Mata v. Avianca, 2023). El 11 y el 12 de abril, el tribunal ordenó presentar copias de los fallos (Mata v. Avianca, 2023). El 25 de abril se entregaron extractos, no textos completos, y uno de los fallos «no se encontró» (Mata v. Avianca, 2023). Los documentos falsos tenían señales visibles: análisis incoherente, números que correspondían a otras causas y jueces reales presentados como autores (Mata v. Avianca, 2023). Recién el 25 de mayo se reconoció que los casos venían de ChatGPT; en total, seis decisiones resultaron inexistentes (Mata v. Avianca, 2023).

El 22 de junio de 2023, el tribunal declaró mala fe de ambos abogados, por evitar confirmar lo que las señales indicaban y por hacer declaraciones falsas o engañosas (Mata v. Avianca, 2023). Les impuso una multa de 5.000 dólares, solidaria con el estudio, y la obligación de escribir al cliente y a cada juez presentado como autor de un fallo falso (Mata v. Avianca, 2023).

La segunda historia es Moffatt v. Air Canada. El 11 de noviembre de 2022, tras la muerte de su abuela, un pasajero preguntó al chatbot del sitio de Air Canada por la tarifa por duelo (Moffatt v. Air Canada, 2024). El chatbot le dijo que podía pedirla después de viajar, dentro de 90 días (Moffatt v. Air Canada, 2024). La página de la política, enlazada en esa misma respuesta, decía lo contrario (Moffatt v. Air Canada, 2024). El pasajero compró y pidió el descuento a tiempo. El 8 de febrero de 2023, un representante de la aerolínea reconoció que el chatbot había usado palabras engañosas (Moffatt v. Air Canada, 2024). Ante el tribunal, en cambio, Air Canada sostuvo que no respondía por lo que dijera el chatbot (Moffatt v. Air Canada, 2024). El 14 de febrero de 2024, el tribunal lo rechazó: la empresa responde por toda la información de su sitio y el cliente no tenía por qué contrastar una página con otra (Moffatt v. Air Canada, 2024). Le ordenó pagar 812,02 dólares canadienses (Moffatt v. Air Canada, 2024).

› 3. Análisis guiado

1. Con lo que sabes sobre las formas de alucinación, ¿cuáles aparecen en la primera historia? Encuentra al menos tres. En la segunda, ¿el error del chatbot es una alucinación, una contradicción con el texto de origen o no se puede saber? Justifica con lo que dice la resolución.
2. El abogado le preguntó a ChatGPT si los casos eran reales. Explica por qué eso no es verificar. ¿Qué fuentes confiables habrían servido para comprobar un fallo judicial?
3. Haz una lista de los momentos de la primera historia en que había una señal de alerta.

4. El abogado que firmó revisó solo el estilo y confió en su colega. Relaciónalo con lo que viste sobre la responsabilidad profesional de quien usa la IA. En tu cargo, ¿qué documentos firmas o envías con tu nombre? ¿Qué revisarías antes, aunque te lo haya preparado otra persona o una IA?
5. En la segunda historia, el chatbot enlazaba una página que decía lo contrario. ¿Qué habría descubierto alguien que abriera el enlace? El tribunal dijo que esa revisión no le correspondía al cliente. Si tú estuvieras a cargo del contenido del chatbot en la empresa, ¿qué contrastarías, y contra qué fuentes, antes de publicarlo?
6. En la primera historia, el error se reconoció recién meses después de la primera alerta. En la segunda, la empresa lo reconoció por correo, pero luego negó responder por él ante el tribunal. ¿Cómo se ve la honestidad intelectual cuando descubres un error después de haberlo compartido?

› 4. Aplicación a tu proyecto

En el Hito 1 armas tu biblioteca de prompts v1 para un desafío real de tu cargo. Algunas de tus plantillas piden información que no está en un texto tuyo: requisitos, normas, datos o plazos. Esas son las de más riesgo, y esta actividad les agrega una regla de validación. El producto es una tabla de validación y una plantilla corregida, en media página.

1. Elige una plantilla de tu biblioteca que pida datos verificables, por ejemplo «qué plazo tiene un proveedor para emitir una nota de crédito» o «qué documentos exige la empresa para rendir gastos».
2. Pásala por tu asistente y marca tres afirmaciones verificables de la respuesta.
3. Completa una tabla de validación con dos fuentes confiables por afirmación (un sitio oficial, el instructivo de tu empresa, la persona responsable) y tu decisión: mantener, corregir o descartar.
4. Escribe la versión corregida, solo con lo verificado, y marca como «no verificado» lo que no pudiste confirmar.
5. Mejora la plantilla con una medida de prevención: entregarle el texto de origen o permitirle decir «no lo sé».
6. Agrega a la ficha de la plantilla una línea con su regla de validación: qué revisas antes de usar esa respuesta.

No pongas datos personales ni información sensible de tu empresa en los prompts ni en la tabla.

› 5. Autocorrección

1. Nombra casos inexistentes, jueces reales presentados como autores y números de causas que correspondían a otros casos. Para la segunda historia, reconoce que la respuesta contradice la página de la política (no siguió el texto de origen) y que, como la empresa no informó la tecnología, no se puede afirmar que fuera una alucinación de IA generativa.
2. Explica que el mismo sistema puede repetir el error con la misma seguridad y que verificar exige una fuente externa. Propone fuentes como la base oficial de fallos del tribunal, una base de jurisprudencia reconocida o la secretaría del tribunal, y buscar el texto completo, no un extracto.
3. Identifica al menos tres señales: la respuesta de Avianca, las órdenes del tribunal, el caso que no apareció, los extractos sin texto completo. Las une con pasos de validación: abrir la

fuente, rastrear hasta el original, contrastar con dos fuentes y descartar lo que no se puede verificar.

4. Distingue revisar el estilo de revisar el contenido. Afirma que quien firma responde, aunque otra persona o una IA haya hecho el borrador. Nombra documentos concretos de su cargo y qué revisaría en ellos: cifras, nombres, fechas, citas.
5. Señala que el enlace llevaba a la política, que decía lo contrario: una fuente citada no es una fuente verificada. Como responsable del chatbot, propone contrastar sus respuestas con la política oficial y con otra fuente interna, y revisarlas cuando la política cambie.
6. Menciona reconocer el error pronto, decirlo con claridad, corregirlo y no presentar como seguro lo que no lo es. Relaciona esto con lo que costó no hacerlo en la primera historia y con la contradicción de la segunda.

› 6. Para el foro

El tribunal canadiense dijo que no era razonable pedirle al cliente que revisara una parte del sitio web contra otra. ¿Dónde pondrías tú el límite entre lo que debe verificar quien usa una respuesta automática y lo que debe garantizar quien la ofrece? Da un ejemplo de tu trabajo o de tu experiencia como cliente.

› Referencias bibliográficas

Mata v. Avianca, Inc. (2023, 22 de junio). *Opinion and order on sanctions (22-cv-1461 [PKC])*. Tribunal de Distrito de los Estados Unidos para el Distrito Sur de Nueva York. https://storage.courtlistener.com/recap/gov.uscourts.nysd.575368/gov.uscourts.nysd.575368.54.0.pdf

Moffatt v. Air Canada. (2024, 14 de febrero). *Decisión 2024 BCCRT 149 (expediente SC-2023-005609)*. Civil Resolution Tribunal de Columbia Británica. https://decisions.civilresolutionbc.ca/crt/crtd/en/item/525448/index.do