M1-C2 · Cuando la IA inventa: abogados y jurisprudencia inexistente (Mata v. Avianca, 2023) y chatbot de Air Canada (2024)

Aprendizajes esperados que trabaja: M1-AE4 (Validación de resultados)
Hito del proyecto con el que conecta: Hito 1 · Problema u oportunidad real + biblioteca de prompts v1

1. Contexto

Fuentes: F-M1C2-01, F-M1C2-03

Este caso junta dos historias de mundos distintos: un estudio de abogados en Nueva York y una aerolínea en Canadá. En las dos, alguien confió en un texto producido por un sistema automático sin contrastarlo con la fuente original. Y en las dos, una autoridad dejó todo por escrito en una resolución pública: un tribunal federal de Estados Unidos y un tribunal civil de Columbia Británica.

Eso es lo valioso. No dependemos de lo que contó la prensa: sabemos qué se revisó, qué no se revisó y qué consecuencias tuvo.

En la primera historia, un abogado usó ChatGPT para buscar fallos que apoyaran su argumento, y el chatbot los inventó. En la segunda, el chatbot del sitio web de Air Canada le dio a un pasajero una regla equivocada sobre los descuentos por duelo. Un detalle importante: Air Canada no informó al tribunal qué tecnología usaba su chatbot. Por eso no podemos afirmar que fuera IA generativa. Lo que sí está probado es que la respuesta automática estaba equivocada y que alguien tuvo que responder por ella.

¿Por qué importa para ti? Porque en cualquier cargo vas a firmar, enviar o publicar textos. Este caso muestra, con hechos, lo que viste en M1-AE4: una respuesta que suena segura no es una respuesta verificada.

2. Qué pasó

Fuentes: F-M1C2-01, F-M1C2-02, F-M1C2-03

Historia 1 · Mata v. Avianca (tribunal federal, Nueva York). Un pasajero demandó a Avianca por una lesión en un vuelo. Avianca pidió rechazar la demanda por estar fuera de plazo. Un abogado del estudio hizo la investigación; otro firmó y presentó los escritos.

Fecha	Qué pasó
01-03-2023	El escrito de respuesta cita decisiones judiciales que no existen. Quien firma lo revisó solo por estilo y no leyó ningún fallo citado
15-03-2023	Avianca avisa que no encuentra la mayoría de los casos. Nadie retira el escrito
11 y 12-04-2023	El tribunal ordena presentar copias de los fallos
25-04-2023	Se presentan extractos, no textos completos; un fallo «no se encontró»
25-05-2023	Por primera vez se reconoce que los casos venían de ChatGPT
22-06-2023	Resolución de sanciones. Ese mismo día, en otra resolución, la demanda se rechaza por estar fuera de plazo

Qué se verificó y qué no, según el tribunal:

- El abogado que investigó usó ChatGPT como única fuente. Pedía «casos que respalden» su postura, y el chatbot los inventó.
- Buscó el texto completo de uno de los casos, no lo encontró y no lo informó.
- Para comprobar, le preguntó al propio ChatGPT si los casos eran reales. El chatbot respondió que sí.
- Los fallos falsos tenían señales visibles: análisis incoherente, números de otras causas, jueces reales como supuestos autores. Seis decisiones resultaron inexistentes.

Consecuencias: el tribunal declaró mala fe de ambos abogados, por evitar confirmar lo que las señales indicaban y por hacer declaraciones falsas o engañosas al tribunal. Impuso una multa de 5.000 dólares, solidaria con el estudio, y la obligación de enviar cartas al cliente y a cada juez presentado como autor de un fallo falso.

Historia 2 · Moffatt v. Air Canada (Civil Resolution Tribunal, Columbia Británica). El 11-11-2022, tras la muerte de su abuela, un pasajero preguntó al chatbot del sitio de Air Canada por la tarifa por duelo. El chatbot le dijo que podía pedirla después de viajar, dentro de 90 días. La

página de la política, enlazada en esa misma respuesta, decía lo contrario. El pasajero compró y pidió el descuento a tiempo. El 08-02-2023, un representante de la aerolínea reconoció que el chatbot había usado palabras engañosas.

Ante el tribunal, Air Canada sostuvo que no respondía por lo que dijera el chatbot. El 14-02-2024, el tribunal lo rechazó: la empresa responde por toda la información de su sitio y el cliente no tenía por qué contrastar una página con otra. Ordenó pagar 812,02 dólares canadienses.

3. Análisis guiado

Cubre: M1-AE4:S1, M1-AE4:S2, M1-AE4:S3, M1-AE4:H1, M1-AE4:A1, M1-AE4:A2, M1-AE4:C1, M1-AE4:C2

1. **Qué tipo de error.** Revisa M1-AE4 P03. ¿Qué formas de alucinación aparecen en la historia 1? Encuentra al menos tres (por ejemplo, casos que no existen). En la historia 2, ¿el error del chatbot es una alucinación, una contradicción con el texto de origen (P06) o no se puede saber? Justifica con lo que dice la resolución.
2. **Preguntarle al mismo asistente.** El abogado le preguntó a ChatGPT si los casos eran reales. Con M1-AE4 P13, explica por qué eso no es verificar. ¿Qué fuentes confiables (P08) habrían servido para comprobar un fallo judicial?
3. **Las señales que nadie atendió.** Haz una lista de los momentos de la historia 1 en que había una señal de alerta. Para cada uno, ¿qué paso de tu checklist de validación (M1-AE4 P12) habría cambiado el resultado?
4. **Quien firma responde.** El abogado que firmó revisó solo el estilo y confió en su colega. Relaciónalo con la responsabilidad profesional (M1-AE4 P16). En tu cargo, actual o al que postulas, ¿qué documentos firmas o envías con tu nombre? ¿Qué revisarías tú antes, aunque te lo haya preparado otra persona o una IA?
5. **El chatbot y la página.** En la historia 2, el chatbot enlazaba una página que decía lo contrario. Con M1-AE4 P11, ¿qué habría descubierto alguien que abriera el enlace? El tribunal dijo que esa revisión no le correspondía al cliente. Si tú estuvieras a cargo del contenido del chatbot en la empresa, ¿qué contrastarías y contra qué fuentes, antes de publicarlo?
6. **Reconocer el error.** En la historia 1, el tribunal dijo que todo habría sido distinto si los abogados hubieran reconocido el error apenas Avianca avisó o el tribunal pidió los fallos. En la historia 2, la empresa reconoció el error por correo, pero luego negó responder por él ante el tribunal. Con M1-AE4 P16 y P17, ¿cómo se ve la honestidad intelectual cuando descubres un error después de compartirlo?

4. Aplicación a tu proyecto

En el Hito 1 armas tu **biblioteca de prompts v1** para un desafío laboral real, tomado de un cargo que ejerces o de una oferta de empleo. Algunas de tus plantillas piden información que no está en un texto tuyo: requisitos, normas, datos o plazos. Esas son las de más riesgo. Esta actividad les agrega una regla de validación.

Producto: una tabla de validación y una plantilla corregida (media página).

1. Elige una plantilla de tu biblioteca que pida datos verificables. Si hoy no trabajas, usa el aviso de empleo de tu proyecto: por ejemplo, «qué exige la ley para este cargo» o «qué certificación piden para este puesto».
2. Pásala por tu asistente y **marca tres afirmaciones verificables** de la respuesta.
3. Completa la **tabla de validación** de M1-AE4 P15: dos fuentes confiables por afirmación y tu decisión (mantener, corregir o descartar).
4. Escribe la **versión corregida**, solo con lo verificado. Marca como «no verificado» lo que no pudiste confirmar.
5. Mejora la plantilla con una medida de prevención (M1-AE4 P14): entregarle el texto de origen o permitirle decir «no lo sé».
6. Agrega a la ficha de la plantilla, en tu biblioteca, una línea: **«Regla de validación: qué reviso antes de usar esta respuesta»**.

No incluyas datos personales en los prompts ni en la tabla.

5. Autocorrección

1. Nombra casos inexistentes, citas atribuidas a fallos reales que no las contienen, jueces reales presentados como autores y números de causas que correspondían a otros casos. Para la historia 2, reconoce que la respuesta contradice la página de la política (no siguió el texto de origen) y que, como la empresa no informó la tecnología, no se puede afirmar que fuera una alucinación de IA generativa.
2. Explica que el mismo sistema puede repetir el error con la misma seguridad y que verificar exige una fuente externa. Propone fuentes como la base oficial de fallos del tribunal, una base de jurisprudencia reconocida o la secretaría del tribunal, y buscar el texto completo, no un extracto.
3. Identifica al menos tres señales: la respuesta de Avianca, las órdenes del tribunal, el caso que no apareció, los extractos sin texto completo, un fallo que «no se encontró». Las une con pasos del checklist: abrir la fuente, rastrear hasta el original, contrastar con dos fuentes y decidir descartar lo no verificable.

4. Distingue revisar el estilo de revisar el contenido. Afirma que quien firma responde, aunque otra persona o una IA haya hecho el borrador. Nombra documentos concretos de su cargo y qué revisaría (cifras, nombres, fechas, citas).
5. Señala que el enlace llevaba a la página de la política, que decía lo contrario: una fuente citada no es una fuente verificada. Como responsable del chatbot, propone contrastar sus respuestas con la política oficial y con otra fuente interna, y revisarlas cuando la política cambie.
6. Menciona reconocer el error pronto, decirlo con claridad, corregirlo y no presentar como seguro lo que no lo es. Relaciona con el costo de no hacerlo en la historia 1 y con la contradicción de la historia 2.

6. Para el foro

El tribunal canadiense dijo que no era razonable pedirle al cliente que revisara una parte del sitio web contra otra. ¿Dónde pondrías tú el límite entre lo que debe verificar quien usa una respuesta automática y lo que debe garantizar quien la ofrece? Da un ejemplo de tu experiencia como cliente o como trabajador.

Fuentes

- F-M1C2-01 · Tribunal de Distrito de EE. UU., Distrito Sur de Nueva York (22-06-2023). Mata v. Avianca, Inc., 22-cv-1461 (PKC), Opinion and Order on Sanctions. https://storage.courtlistener.com/recap/gov.uscourts.nysd.575368/gov.uscourts.nysd.575368.54.0.pdf
- F-M1C2-02 · Tribunal de Distrito de EE. UU., Distrito Sur de Nueva York (22-06-2023). Mata v. Avianca, Inc., 22-cv-1461 (PKC), Opinion and Order. https://storage.courtlistener.com/recap/gov.uscourts.nysd.575368/gov.uscourts.nysd.575368.55.0.pdf
- F-M1C2-03 · Civil Resolution Tribunal de Columbia Británica (14-02-2024). Moffatt v. Air Canada, 2024 BCCRT 149. https://decisions.civilresolutionbc.ca/crt/crtd/en/item/525448/index.do